ТЕХНИЧЕСКИ УНИВЕРСИТЕТ – СОФИЯ

ФАКУЛТЕТ КОМПЮТЪРНИ СИСТЕМИ И ТЕХНОЛОГИИ

КУРСОВ ПРОЕКТ

Дисциплина: Невронни Мрежи

Тема:

Класификация на изображения от събитийно-базиран тип чрез пикови невронни мрежи върху набора CIFAR10-DVS

Изготвил:
Асен Пантелеев Попов
Фак. № 121223246
Група 38
III курс, КСИ
e-mail: `asepopov@tu-sofia.bg`

Ръководител:
проф. Румен Трифонов

София, 2026 г.

Съдържание

1 Увод **2**

2 Теоретична основа **2**

3 Набор от данни и предварителна обработка **5**

4 Методология и реализация **7**

5 Архитектури на моделите **7**

6 Проведени експерименти **9**

7 Резултати и анализ **9**

8 Обсъждане **12**

9 Заключение **12**

1 Увод

През последните години пиковите невронни мрежи (Spiking Neural Networks, SNN) и невроморфните сензори привличат все по-голям интерес, тъй като предлагат модел на обработка, който е по-близък до биологичните нервни системи в сравнение с класическите изкуствени невронни мрежи. За разлика от стандартните изображения, при събитийно-базираното зрение информацията не се подава като плътни кадри с фиксирана честота, а като асинхронен поток от събития, които описват локални промени в яркостта. Това прави задачите върху DVS данни едновременно по-ефективни по отношение на времева резолюция и по-трудни от гледна точка на моделиране, обучение и интерпретация.

В контекста на този проект целта е да бъде разработена завършена, възпроизводима и структурирана система за класификация на събитийни изображения чрез `snnTorch` върху набора CIFAR10-DVS. Проектът комбинира модулен Python код, Jupyter notebooks за експерименти и визуализации, както и систематичен сравнителен анализ на няколко архитектурни и обучителни варианта. Практическата мотивация е да се оцени доколко хибриден CNN+SNN подход може да постигне надеждно качество върху умерено труден невроморфен набор от данни и кои проектни решения водят до най-добър компромис между точност, стабилност и сложност на модела.

Резултатът от проекта е работеща система за зареждане, предварителна обработка, обучение и оценяване върху CIFAR10-DVS, както и финален модел с най-добро качество от проведените експерименти: `wider_10bins_10epochs`, който постига тестова точност приблизително 52.93%.

2 Теоретична основа

Пиковите невронни мрежи използват импулсно представяне на информацията, при което невроните комуникират чрез дискретни пикове във времето, а не чрез непрекъснати активации. Този тип модели са особено подходящи за обработка на времеви сигнали и събитийно-базирани данни, тъй като самата входна информация е събитийна по природа. В литературата SNN често се разглеждат като естествено продължение на класическите изкуствени невронни мрежи към по-реалистични модели на невронна динамика, времева зависимост и енергийно ефективни невроморфни реализации [1].

Особено значима фигура в тази област е Никола Касабов, чиито трудове върху пространствено-времевите пикови невронни мрежи и мозъчно-вдъхновените интелигентни системи систематизират връзката между времевото кодиране, пространствените зависимости и адаптивното обучение в SNN [1]. Подходът на Касабов е важен за настоящия проект, защото поставя фокус върху това, че при събитийни данни времето не е второстепенен атрибут, а фундаментална част от представянето

на информацията. Именно затова при DVS задачи архитектурите трябва да умеят не само да извличат пространствени характеристики, но и да съхраняват, агрегират и интерпретират динамиката във времето. В този смисъл пиковите мрежи са естествен кандидат за работа със събитийни сигнали, тъй като времето участва пряко в кодирането и обработката на информацията.

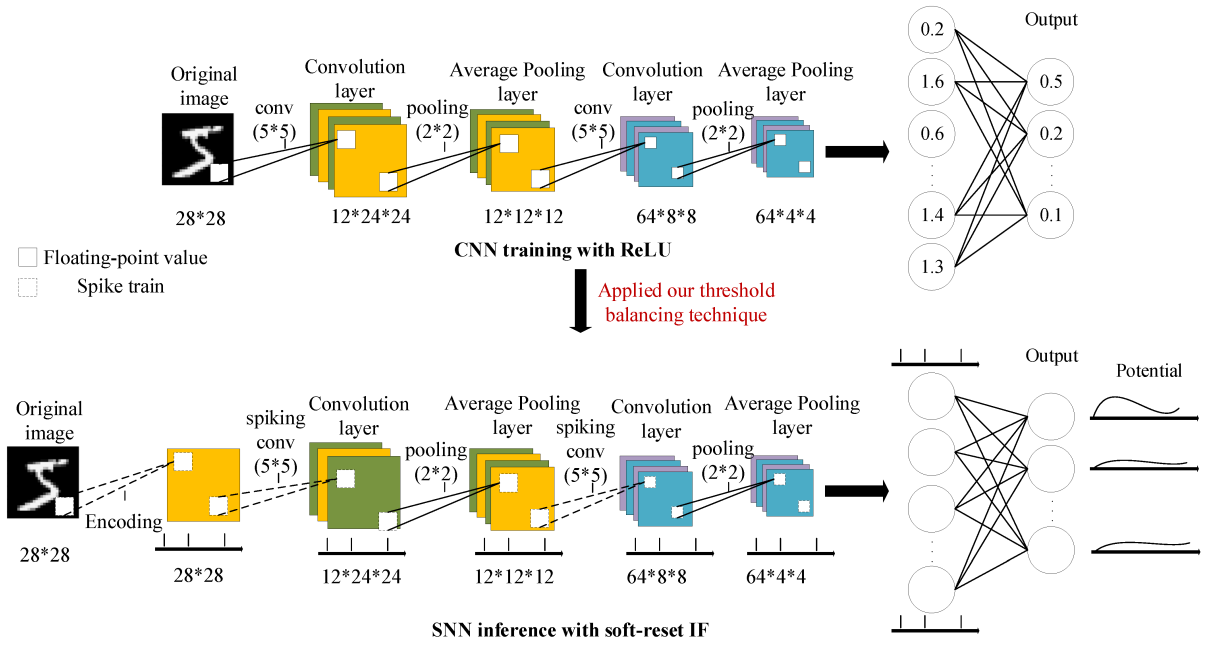

Фигура 1: Илюстративен пример за хибридна CNN+SNN архитектура, при която конволюционната обработка се комбинира с пикова инференция. Фигурата е адаптирана по Ngu и Lee [3].

От гледна точка на входните данни, събитийно-базираните камери от тип Dynamic Vision Sensor (DVS) не измерват абсолютна яркост във фиксирани кадри, а генерират събития, когато локалната логаритмична яркост премине определен праг. Всяко събитие съдържа пространствена позиция, полярност и времева маркировка. Това води до много по-висока времева разделителна способност и до по-рядко, но по-информативно представяне. Същевременно задачите за класификация върху DVS набори са по-трудни, защото информацията е шумна, разредена и силно зависима от начина на запис и преобразуване. Освен това тези камери реагират на промяна, а не на статична сцена, което означава, че полезната информация зависи от динамиката на наблюдавания обект и от механизма на движение в процеса на запис [9, 8, 10].

Практическата стойност на DVS камерите идва именно от комбинацията между ниска латентност, ниска излишност на данните и висока чувствителност към динамика. Поради това те намират приложение в роботиката, автономните превозни средства, мрежите от визуални сензори, системите за координация между множество агенти и други сценарии, при които промените във времето са по-важни от пълното възстановяване на всеки кадър [4].

Фигура 3 илюстрира ключовата разлика между класическите камери и събитий-

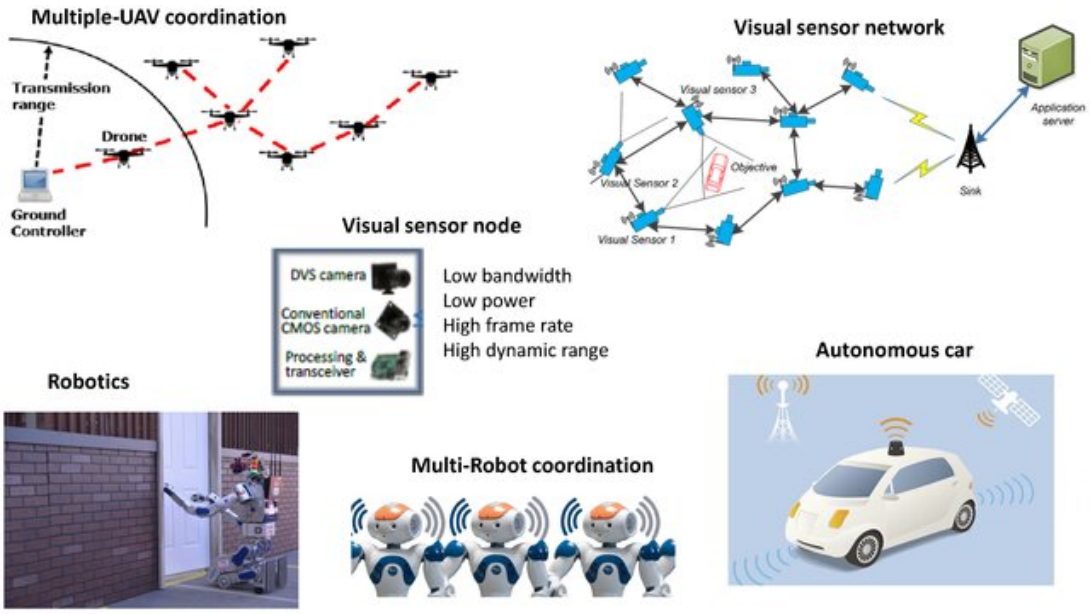

Фигура 2: Примерни приложения на DVS камерите във визуални сензорни мрежи, роботика, координация на автономни системи и интелигентни транспортни платформи [4].

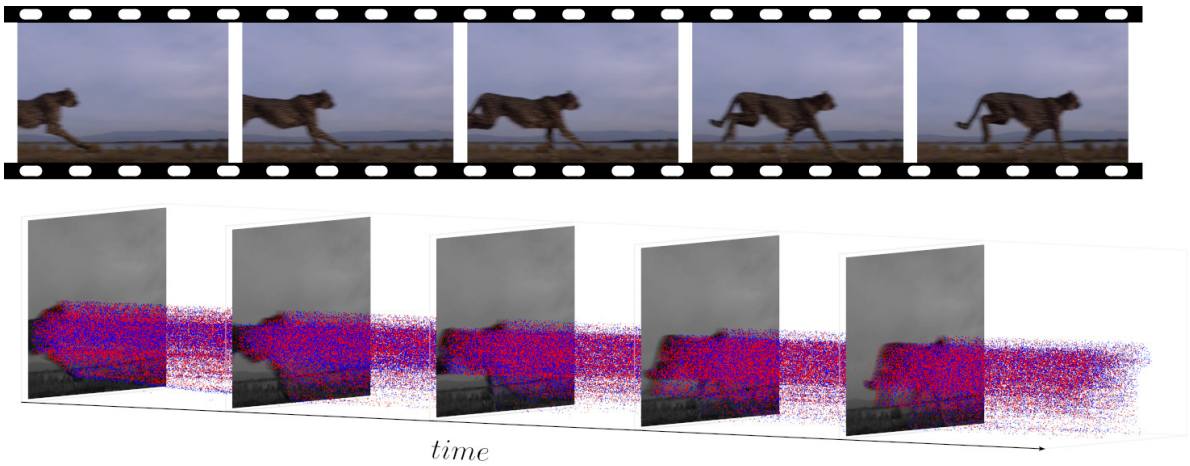

Фигура 3: Сравнение между кадрово представяне от стандартна камера и събитийно представяне от event camera във времето [5].

ните сензори. При стандартната камера информацията се събира в последователност от пълни кадри, докато при event camera се записват само локалните промени, което води до разредено, но времево много по-богато представяне. Именно тази особеност прави DVS камерите особено интересни за пиковите невронни мрежи, тъй като и входът, и моделът са естествено ориентирани към обработка на събития във времето.

В сравнение с класическия CIFAR-10, наборът CIFAR10-DVS е значително по-предизвикателен. Според оригиналната публикация той е създаден чрез преобразуване на 10 000 изображения от CIFAR-10 в поток от събития посредством повтарящо се плавно движение по затворена траектория и DVS камера с резолюция 128x128 [2]. Авторите изрично го позиционират като набор със средна трудност: по-сложен от MNIST-DVS, но по-опростен от N-Caltech101. Те подчертават още, че сложният фон и по-богатите контури в CIFAR-10 водят до значително по-сложни пространствено-времеви структури от тези в MNIST-подобните набори. Следователно е напълно нормално точността при CIFAR10-DVS да бъде осезаемо по-ниска от типичните резултати при кадровия CIFAR-10.

Оригиналният ориентировъчен benchmark в статията за CIFAR10-DVS е показателен за тази трудност. Авторите докладват, че при работа директно върху събитийните записи класически статистически характеристики с KNN достигат около 16.80%, spike-based forward neural network (SFNN) достига 22.10%, BOE-SVM достига 24.21%, а BOE-Random Forest достига 29.67% [2]. Тези стойности не са директно сравними едно към едно с настоящия проект, тъй като тук се използва преобразуване от събития към кадри и по-съвременен подход за дълбоко обучение. Въпреки това те дават важен контекст: CIFAR10-DVS не е "лесен" набор и дори умерени подобрения над ранните ориентировъчни резултати са съществени.

3 Набор от данни и предварителна обработка

За проекта е използван наборът CIFAR10-DVS, който съдържа 10 класа обекти: *airplane*, *automobile*, *bird*, *cat*, *deer*, *dog*, *frog*, *horse*, *ship* и *truck*. Данните са организирани като потоци от събития във формат `.aedat4`, които бяха заредени чрез библиотеката `Tonic`. Практическият работен процес при проекта комбинира автоматичното API на `Tonic` с локално съхранение на архива и извлечените файлове в `data/raw/CIFAR10DVS`.

Тъй като повечето модели в `snnTorch` и в стандартния PyTorch работен процес работят по-лесно с тензорно представяне, потокът от събития беше преобразуван в последователност от дискретни кадри чрез `tonic.transforms.ToFrame`. По този начин събитията се агрегират в краен брой времеви бинове, а всяка извадка получава форма (T, C, H, W), където T е броят времеви стъпки, $C = 2$ е броят канали за двете полярности, а $H = W = 128$. Избраният подход е компромис между работа

директно върху суровия поток от събития и необходимостта от практично, стабилно и сравнително лесно за обучение тензорно представяне.

В notebook-а за предварителна обработка бяха сравнени няколко представяния с различен брой времеви бинове: 5, 10 и 20. Експерименталният анализ показа, че при 5 бина пространствената структура на обекта е по-плътна, но част от темпоралната информация се компресира. При 20 бина представянето става по-разредено, което затруднява извличането на стабилни признаци от модела. Вариантът с 10 бина се оказа най-балансиран компромис между детайл и плътност, поради което беше избран за основните обучителни експерименти. Заедно с това беше запазено двуканалното представяне на полярностите и нормализацията на входовете.

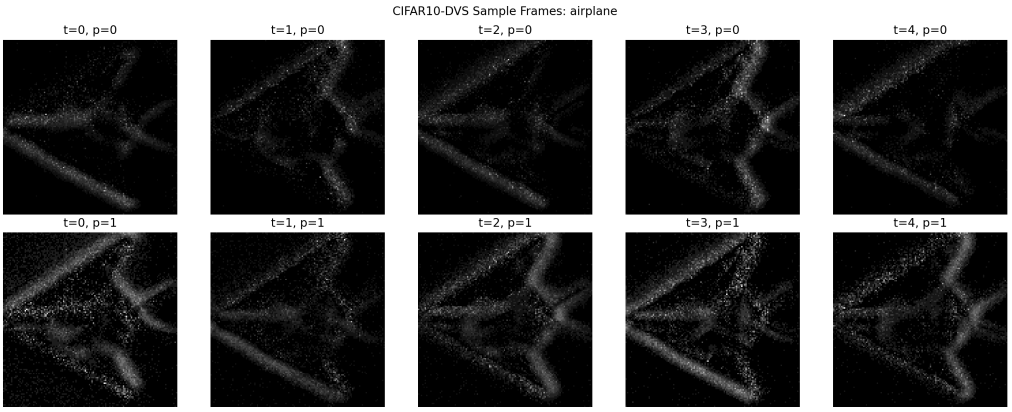

Фигура 4: Примерни кадри от CIFAR10-DVS за една извадка, представени по времеви стъпки и полярности.

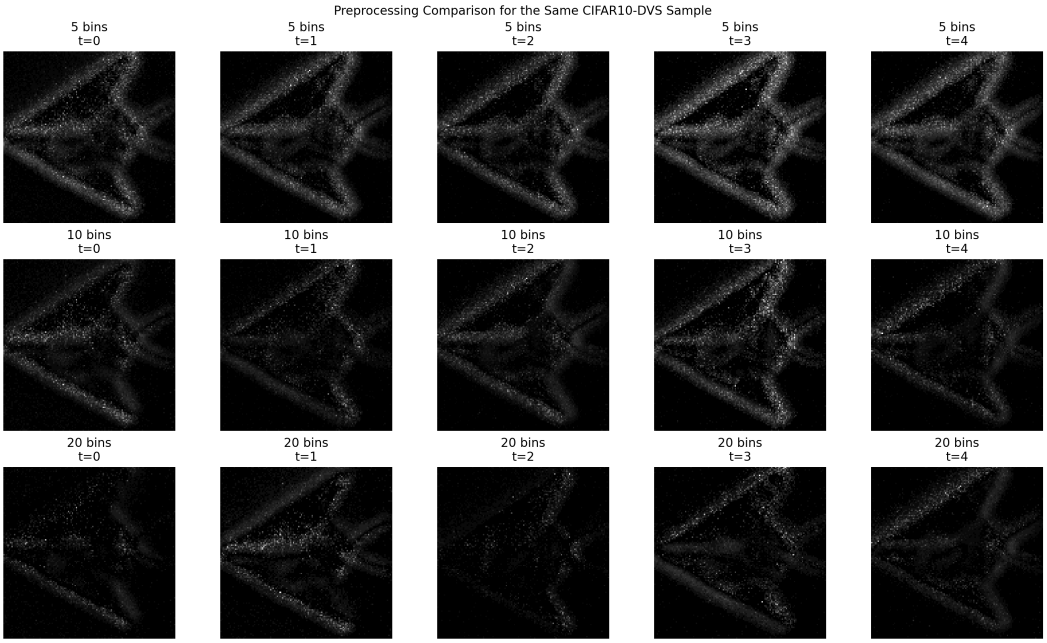

Фигура 5: Сравнение на различни варианти за предварителна обработка чрез 5, 10 и 20 времеви бина.

4 Методология и реализация

Проектът беше реализиран като комбинация от модулен Python код и Jupyter notebooks. Основната логика е организирана в пакет `src/snn_cifar10dvs`, който включва отделни модули за конфигурация, зареждане на данни, предварителна обработка, дефиниция на модели, обучение, оценяване и помощни функции. Тази организация позволи експериментите в notebooks да използват един и същ reusable код, без логиката да бъде дублирана.

Средата за работа беше дефинирана чрез `environment.yml` и регистрирана като Jupyter kernel, което гарантира възпроизводимост между notebook средата и скриптовото изпълнение. За реализацията бяха използвани основно `PyTorch`, `snnTorch`, `Tonic`, `NumPy`, `Matplotlib` и `scikit-learn`. Това осигури достатъчно стабилен и академично адекватен стек за разработка без излишно усложняване на проекта.

Обучението на моделите беше реализирано чрез стандартен supervised workflow: разделяне на данните на тренировъчен, валидационен и тестов дял, оптимизация с `Adam`, проследяване на загубата и точността във всяка епоха, както и записване на най-добрия checkpoint според валидационната загуба. Конкретно, наборът беше разделен стратифицирано на 70% обучаващ дял, 15% валидационен дял и 15% тестов дял, което при 10 000 примера съответства на 7000/1500/1500 извадки. Това решение се оказа важно, защото при по-силните модели се наблюдава умерено overfitting и последната епоха не винаги дава най-добра генерализация.

Самото обучение беше проведено в Conda среда с регистриран Jupyter kernel, като за изчисленията беше използвана видеокарта `NVIDIA GeForce RTX 4060` с 8 GB графична памет. Това позволи експериментите да бъдат изпълнявани в разумно време, без да се променя програмният интерфейс между notebook средата и модулния код.

Публичната версия на проекта, съдържаща изходния код, notebooks и фигурите за анализа, е достъпна в GitHub хранилището Apsie09/Cifar10-DVS-SNN-Classification.

5 Архитектури на моделите

Първият реализиран модел беше базов хибриден CNN+SNN модел, при който пространствените признаци се извличат чрез последователност от конволюционни слоеве, а класификационната глава използва LIF-базирани пикови неврони чрез `snn.Leaky`. Тази архитектура е прагматична, защото позволява стабилно обучение върху представяне от тип „събития към кадри“ и едновременно с това запазва пиков компонент в крайната времева агрегация.

След първоначалния baseline беше реализиран и по-широк вариант, наречен `wider`, с повече канали в конволюционните слоеве и по-голям скрит слой в класификатора. Целта на този вариант беше да се провери дали baseline архитектурата е ограничена основно от капацитета си. Резултатите показаха, че именно този по-широк хибри-

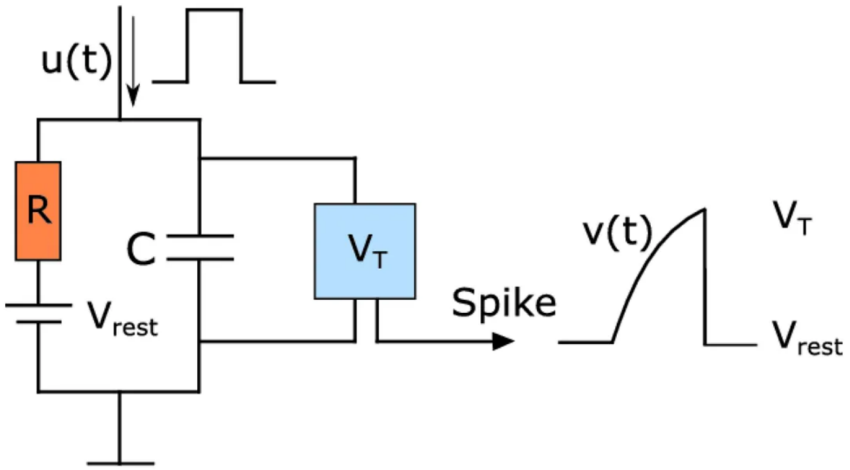

Фигура 6: Илюстрация на логиката на модела Leaky Integrate-and-Fire (LIF), при който входният сигнал се интегрира във времето, мембранният потенциал нараства до праг и при достигането му се генерира пик, след което състоянието се нулира към покойно ниво.

ден модел дава най-доброто качество в проекта. Финалната архитектура използва три последователни конволюционни блока с канали $32 \to 64 \to 128$, следвани от адаптивно pooling до размер 4×4, напълно свързан скрит слой с 512 признака и два LIF-базирани пикови слоя в класификационната част. Общият брой обучаеми параметри е приблизително 1.15 милиона.

Успоредно с това беше тестван и по-силно SNN-ориентиран вариант, вдъхновен от хибридни архитектури от типа Nengo-DL, при които пиковите нелинейности се въвеждат още след конволюционните слоеве. Конкретната идея за този сравнителен вариант беше мотивирана и от публичен демонстрационен пример за класификация на MNIST с NengoDL, представен в блог публикация и съпътстващо GitHub хранилище [6, 7]. Макар идеята да е интересна от теоретична и инженерна гледна точка, на практика този вариант се оказа значително по-слаб върху CIFAR10-DVS в рамките на настоящата постановка. Това е важен отрицателен резултат, защото показва, че по-силно "пиково" решение по цялата архитектура не е непременно по-добро, когато капацитетът и оптимизацията не са достатъчно добре балансирани.

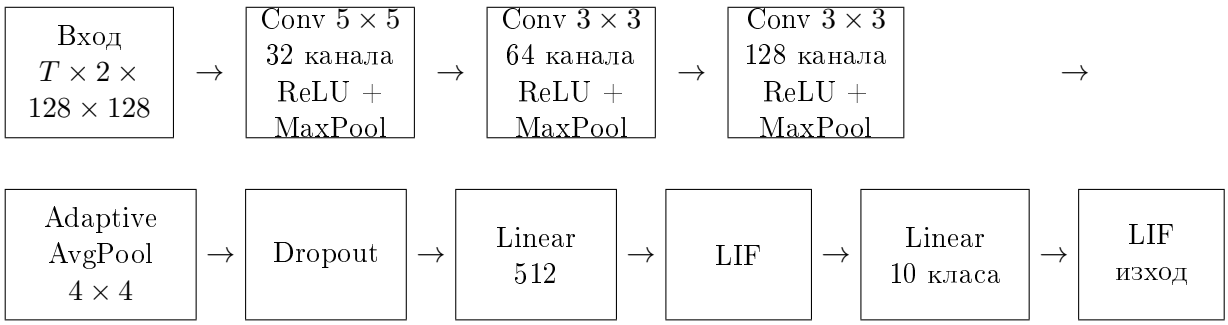

Фигура 7: Схематично представяне на финално избраната архитектура `wider_10bins_10epochs`.

6 Проведени експерименти

Експерименталната част на проекта беше организирана поетапно. Първо беше валидирана цялата система чрез базов модел с 10 времеви бина и 5 епохи обучение. След това вниманието се насочи към два основни въпроса: дали по-голям капацитет подобрява качеството и дали по-агресивна регуляризация или по-SNN-ориентирана архитектура водят до по-добра генерализация.

Първият съществен резултат дойде от сравнението между базовия модел и по-широкия хибриден вариант. Моделът `wider_10bins_10epochs` постигна най-висока тестова точност и показа, че по-големият капацитет е полезен за тази задача. След това бяха разгледани няколко последващи варианта: версия с weight decay 10^{-4}, по-дълго обучение до 15 епохи, batch normalization и Nengo-inspired архитектура. Регуляризацията чрез weight decay доведе до по-стабилно поведение, но влоши крайната тестова точност. Обучението за 15 епохи увеличи тренировъчната точност значително, но без съществено подобрение на теста, което е ясен индикатор за преобучаване. Batch normalization се оказа нестабилен избор при използвания малък размер на пакета и не беше доразвиван. Най-слабият вариант беше Nengo-inspired моделът, който подчерта, че по-рано въведените пикови нелинейности не са достатъчни сами по себе си да подобрят резултатите.

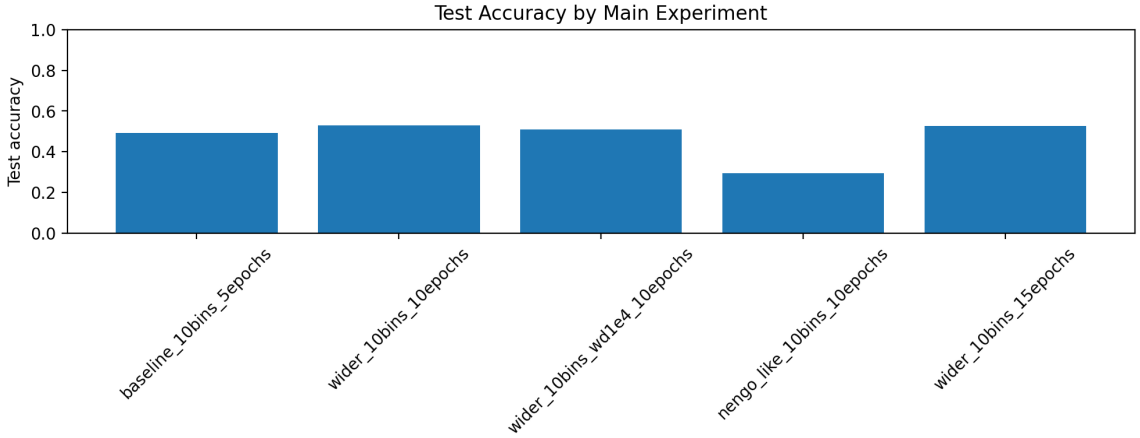

Фигура 8: Сравнение на основните експерименти по тестова точност.

7 Резултати и анализ

Най-добрият модел в проекта е `wider_10bins_10epochs`. Той използва 10 времеви бина, нормализирано двуканално представяне по полярност и по-широка хибридна архитектура от baseline варианта. Постигнатата тестова точност е 52.93%, което е най-добрият резултат сред проведените контролирани сравнения. Заедно с това моделът достига и по-висока валидационна точност спрямо началния baseline, което потвърждава, че подобрението не е случайно.

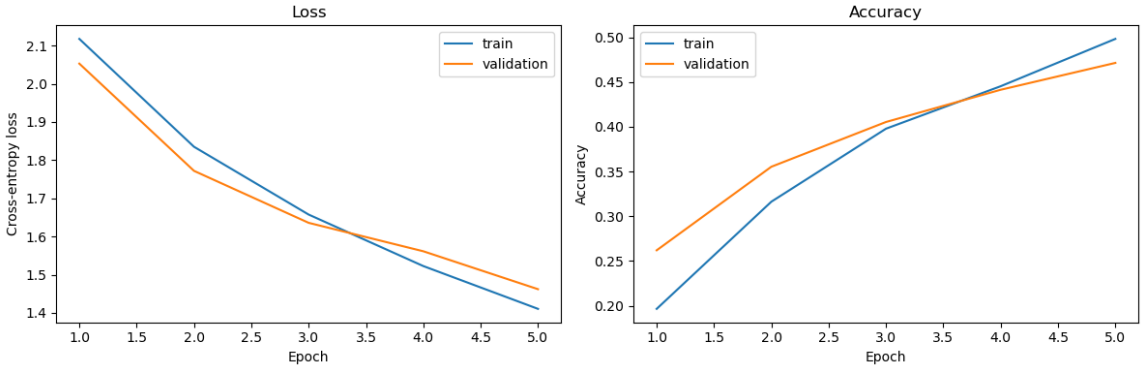

Фигура 9: Първичен резултат след началното обучение в `notebooks/03_training.ipynb`, показващ поведението на базовия модел върху тренировъчния и валидационния дял.

Графиките за загубата и точността показват, че моделът се обучава стабилно до около седма-девета епоха, след което се наблюдава разминаване между тренировъчното и валидационното поведение. Това е типично за модели с по-висок капацитет и за сравнително трудни набори като CIFAR10-DVS. В този смисъл решението да се използва оценяване по най-добре запазения модел вместо оценка само на последната епоха е методологично правилно.

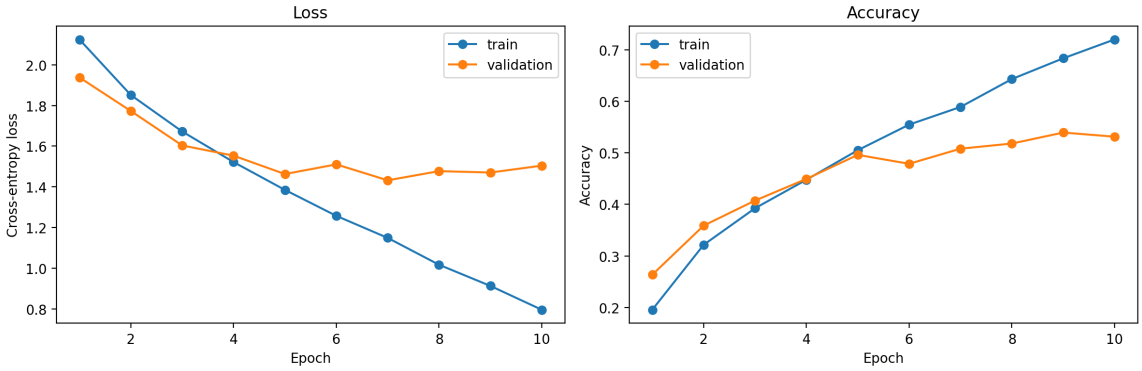

Фигура 10: Криви на обучението за финално избрания модел `wider_10bins_10epochs`.

Матрицата на объркванията за финалния модел показва, че класове като *automobile*, *dog*, *frog*, *horse*, *ship* и *truck* се разпознават относително по-стабилно, докато *bird*, *cat* и *deer* остават по-трудни за разграничаване. Това поведение е логично, тъй като при събитийното представяне някои класове запазват по-ясни динамични и контурни характеристики, докато други се припокриват по отношение на форма и локални структури.

Важно е да се подчертае, че точност около 53% върху CIFAR10-DVS е напълно смислен резултат в рамките на курсов проект с ограничен брой контролирани експерименти и без използване на силно оптимизирани архитектури от най-новата литература. Оригиналната публикация за набора подчертава именно нуждата от

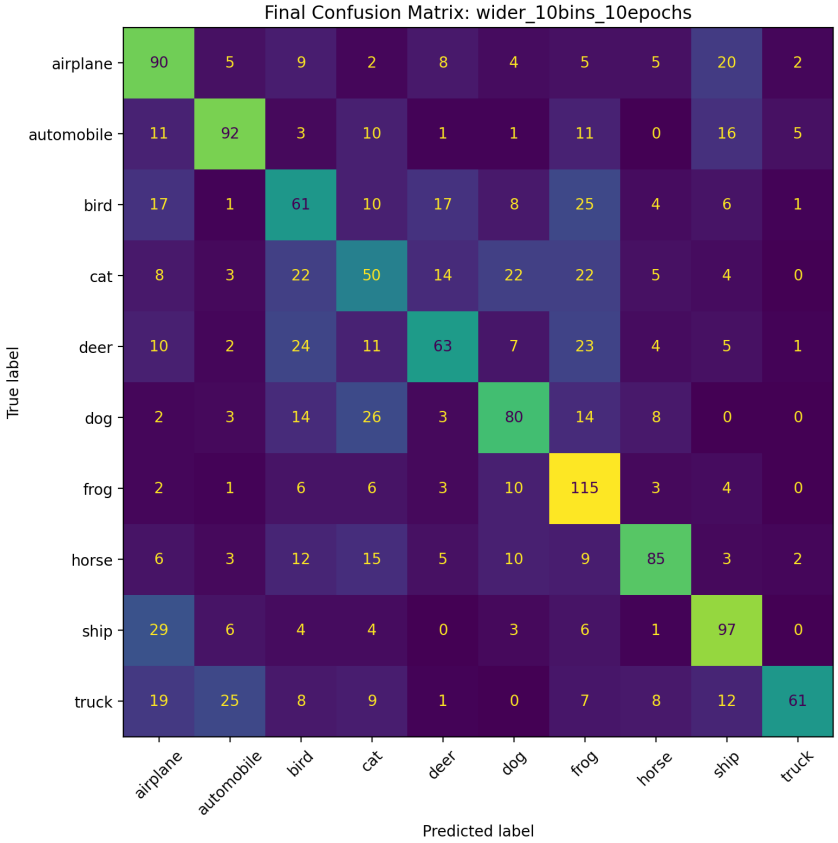

Фигура 11: Матрица на объркванията за финално избрания модел.

по-нататъшно развитие на събитийно-ориентираните алгоритми и предлага сравнително скромни начални ориентировъчни резултати [2]. Следователно наблюдаваното качество в този проект е в съответствие с факта, че става дума за умерено труден невроморфен набор, при който кадровите интуиции не се пренасят директно.

Метод	Точност
KNN със статистически характеристики	16.80%
SFNN	22.10%
BOE-SVM	24.21%
BOE-Random Forest	29.67%
Наш финален модел `wider_10bins_10epochs`	52.93%

Таблица 1: Контекст за резултатите: benchmark-и от оригиналната статия за CIFAR10-DVS и финален резултат от проекта.

Таблица 1 не трябва да се интерпретира като строго директно сравнение между идентични експериментални протоколи, защото използваните представяния и модели са различни. Въпреки това тя е ценна, защото показва, че резултатът в настоящия проект стои убедително над ранните ориентировъчни резултати, докладвани в оригиналната работа за CIFAR10-DVS. Това подкрепя извода, че реализираната система е не само функционална, но и реално конкурентна в рамките на академичен проект

с ограничен мащаб.

8 Обсъждане

От практическа гледна точка най-важният извод от проекта е, че при използвания подход „събития към кадри“ хибридният CNN+SNN модел е по-ефективен от по-“чисто” пиковия вариант. Това не означава, че по-дълбоките SNN архитектури са принципно по-слаби, а по-скоро че в конкретния случай стабилното извличане на пространствени признаци чрез конволюционен front-end е по-подходящо за CIFAR10-DVS и за наличния експериментален ресурс.

Вторият важен извод е, че увеличаването на капацитета помага до определена степен, но след това преобучаването започва да доминира. По-дълго обучение без допълнителен механизъм за генерализация не доведе до реален напредък на тестовия набор. Това показва, че бъдещо подобрение вероятно би дошло не от просто “повече епохи”, а от по-внимателна комбинация между архитектура, график за промяна на learning rate, по-фина регуляризация или по-сложни събитийни представяния.

Третият извод е свързан с предварителната обработка. Изборът на 10 времеви бина се оказа важен, защото дава добър баланс между твърде плътно и твърде разредено представяне. Този резултат е в синхрон с идеята, че при DVS данните качеството на времевата дискретизация има пряко отражение върху класификационните характеристики на модела.

9 Заключение

В рамките на настоящия курсов проект беше разработена завършена система за класификация на събитийно-базирани изображения чрез пикови невронни мрежи върху CIFAR10-DVS. Реализацията включва възпроизводима среда, модулен Python код, поредица от Jupyter notebooks за анализ и експерименти, както и ясна процедура за сравнение между няколко архитектурни и обучителни варианта.

Проведеният анализ показа, че най-добър резултат дава хибридният модел, който постига тестова точност 52.93%. Сравнението с базовия модел, с варианта с weight decay, с по-дълго обучение и с Nengo-inspired архитектурата показва, че най-добрият избор за този проект е по-широк CNN+SNN модел с 10 времеви бина и подбор на най-добре запазения модел по валидационна загуба.

Проектът потвърждава, че събитийно-базираната класификация върху DVS данни е по-трудна от стандартната кадрова класификация, но същевременно е подходяща среда за изследване на SNN подходи. В този смисъл получените резултати са достатъчно добри и аргументирани за целите на курсовия проект. Като бъдеща работа могат да се разгледат по-сложни SNN архитектури, по-фини стратегии за времево кодиране, по-добри графици за промяна на learning rate и по-специализирани невроморфни обучителни подходи.

Литература

[1] Nikola K. Kasabov. *Time-Space, Spiking Neural Networks and Brain-Inspired Artificial Intelligence*. Springer, 2019. DOI: https://doi.org/10.1007/978-3-662-57715-8.

[2] Hongmin Li, Hanchao Liu, Xiangyang Ji, Guoqi Li and Luping Shi. CIFAR10-DVS: An Event-Stream Dataset for Object Classification. *Frontiers in Neuroscience*, 11:309, 2017. DOI: https://doi.org/10.3389/fnins.2017.00309.

[3] Huynh Cong Viet Ngu and Keon Myung Lee. Effective Conversion of a Convolutional Neural Network into a Spiking Neural Network for Image Recognition Tasks. *Applied Sciences*, 12(11):5749, 2022. DOI: https://doi.org/10.3390/app12115749.

[4] Ahmed S. Abdalla, Muhammad M. U. Rahman, Sheikh I. Ahamed and Md. Abdus Sobhan. Bandwidth Modeling of Silicon Retinas for Next Generation Visual Sensor Networks. *IEEE Access*, 7:82294–82308, 2019. DOI: https://doi.org/10.1109/ACCESS.2019.2924439.

[5] Wikipedia contributors. Event camera. https://en.wikipedia.org/wiki/Event_camera. Accessed April 13, 2026.

[6] Kevin Wang. MNIST, MNIST, MNIST but spiking. Medium / The Startup, 2020. https://medium.com/swlh/mnist-mnist-mnist-but-spiking-677cacdb3ce4.

[7] Kevin Wang. MNIST_Classification_with_NengoDL. GitHub repository. https://github.com/Wanff/MNIST_Classification_with_NengoDL.

[8] Garrick Orchard, Ajinkya Jayawant, Gregory K. Cohen and Nitish V. Thakor. Converting Static Image Datasets to Spiking Neuromorphic Datasets Using Saccades. *Frontiers in Neuroscience*, 9:437, 2015. DOI: https://doi.org/10.3389/fnins.2015.00437.

[9] Patrick Lichtsteiner, Christoph Posch and Tobi Delbruck. A 128x128 120 dB 15 μs Latency Asynchronous Temporal Contrast Vision Sensor. *IEEE Journal of Solid-State Circuits*, 43(2):566–576, 2008. DOI: https://doi.org/10.1109/JSSC.2007.914337.

[10] Teresa Serrano-Gotarredona and Bernabé Linares-Barranco. Poker-DVS and MNIST-DVS. Their History, How They Were Made, and Other Details. *Frontiers in Neuroscience*, 9:481, 2015. DOI: https://doi.org/10.3389/fnins.2015.00481.

[11] Jason K. Eshraghian et al. snnTorch Documentation. https://snntorch.readthedocs.io/.

[12] Tonic Contributors. Tonic Documentation. https://tonic.readthedocs.io/.